

Análisis y Limpieza del Dataset Spotify 2023 modificado

Branco Rodrigo Merino Huerta
Análisis y Minería de datos para Ingeniería
en Informática
Prof. Eliecer Peña Ancavil
17 de abril de 2026

Contenido

Análisis y Limpieza del Dataset Spotify 2023 modificado	1
Resumen Ejecutivo	1
1. Introducción.....	2
Objetivos del estudio:.....	2
2. Metodología.....	3
Métodos estadísticos usados:	3
3. Análisis de Datos	4
Tratamiento de outliers:	4
Codificación de categóricas:.....	5
4. Discusión.....	6
5. Conclusiones	6
6. Bibliografía.....	7

Resumen Ejecutivo

Este informe detalla el proceso completo de limpieza y preparación del dataset *Spotify 2023 modificado*, el cual contiene 952 entradas e información sobre características musicales y popularidad de canciones. El objetivo principal fue transformar un conjunto de datos con valores faltantes y una alta variabilidad en un dataset consistente y apto para análisis posteriores.

Para ello, se aplicaron técnicas de imputación de valores nulos utilizando la mediana en variables numéricas y la moda en variables categóricas, también se hizo tratamiento de outliers mediante el método del *rango intercuartílico (IQR)*. Además, se realizó la codificación de variables categóricas (**key y mode**) mediante el método *One Hot Encoding*.

Los resultados nos muestran que variables como "**streams**", presentan una alta dispersión debido a la presencia de canciones extremadamente populares (hits), lo que influye directamente en la distribución de los datos. Tras el tratamiento de outliers, se logró reducir el impacto de estos valores extremos, manteniendo la estructura central de la información.

En conclusión, este proceso permitió obtener un dataset limpio, estructurado y confiable, destacando la importancia de una adecuada preparación de datos para garantizar la calidad y validez de futuros análisis.

1. Introducción

En el mundo del análisis de datos, es raro encontrarse con información perfecta. El dataset de Spotify 2023 (modificado) es un excelente ejemplo de esto: Aunque contiene información valiosa, llega con valores faltantes y cifras de reproducción tan altas que pueden dificultar su interpretación.

Por otra parte, el dataset representa un caso real donde coexisten variables numéricas y categóricas, sumado a las métricas altamente variables como streams, lo convierte en un escenario adecuado para aplicar técnicas de limpieza y exploración de datos.

Objetivos del estudio:

- Reutilizar un Pipeline de análisis previamente visto en clases en un nuevo dataset (Spotify 2023 modificado), a su vez adaptándolo a sus características.
- Aplicar técnicas de imputación de valores nulos, tratamiento de outliers y codificación de variables categóricas.
- Analizar e interpretar visualizaciones gráficas (Boxplots e Histogramas), comprendiendo su utilidad para identificar patrones y anomalías en los datos.
- Trabajar con Google Colab, Python y Google Gemini.

2. Metodología

El análisis se realizó en Google Colab, aprovechando la flexibilidad de Python y librerías como Pandas y Seaborn.

El dataset ***Spotify 2023 modificado*** contiene información sobre distintas canciones, incluyendo características musicales como niveles de popularidad. Cuenta con 952 entradas y entre sus variables principales se encuentran:

- ***streams***: cantidad de reproducciones de cada canción.
- ***danceability_%***: qué tanailable es la canción.
- ***energy_%***: nivel de energía musical.
- ***key* y *mode***: características musicales relacionadas con la tonalidad.
- ***released_year*, *released_month* y *released_day***: fecha de lanzamiento.

A diferencia del dataset trabajado anteriormente en clases (relacionado con partidas de LOL), este conjunto de datos se centra en el ámbito musical, lo que implica un cambio en la interpretación de los datos.

Métodos estadísticos usados:

- ✓ **Imputación de valores faltantes**: Las variables numéricas por la mediana y categóricas por la moda.
- ✓ **Métodos de detección visual (gráficos) y tratamiento de outliers (rango intercuartílico - IQR)**: Se identifican valores muy alejados del resto para ajustarlos, ya que distorsionan el análisis general.
- ✓ **Codificación One Hot Encoding de variables categóricas**: Las Variables fueron transformados en variables numéricas mediante la creación de nuevas columnas binarias.
- ✓ **Visualización de datos**: Se utilizaron gráficos como histogramas y boxplots para observar la distribución de los datos, identificar valores atípicos y comparar los resultados antes y después del tratamiento.

3. Análisis de Datos

Tratamiento de outliers:

El análisis mediante boxplots, como se muestra en la Figura 1, permite observar el efecto del tratamiento de outliers en la variable streams. Inicialmente, los datos presentan alta dispersión y valores extremos (hits globales) que generan asimetría positiva. Estos valores no corresponden a errores, sino a casos reales dentro del dataset; sin embargo, pueden distorsionar las métricas al tener un peso desproporcionado. Tras el tratamiento, se reduce la dispersión y los datos se concentran en torno a la mediana, evitando que estos valores influyan en exceso y mejorando la representatividad del conjunto (Merino Huerta, 2026).





Figura 1. Distribución de la variable *streams* antes y después del tratamiento de outliers.

En la Tabla 1 se comparan los estadísticos antes y después del tratamiento de outliers. Se observa una disminución en las medidas de dispersión, lo que indica una menor variabilidad y un conjunto de datos más adecuado para análisis posteriores (Merino Huerta, 2026).

Tabla 1. Comparación cuantitativa de las variables antes y después del tratamiento de outliers.

index	Media antes	Media después	Mediana antes	Mediana después	Max antes	Max después	Desviación estándar antes	Desviación estándar después
released_year	2018.0	2022.0	2022.0	2022.0	2023.0	2023.0	11.0	1.0
released_month	6.0	6.0	6.0	6.0	12.0	12.0	4.0	4.0
released_day	14.0	14.0	13.0	13.0	31.0	31.0	9.0	9.0
in_spotify_playlists	5123.0	2641.0	2224.0	2224.0	52898.0	11985.0	7819.0	2435.0
streams	514137425.0	379028487.0	290530915.0	290379770.0	3703895074.0	1457139296.0	566856949.0	334168551.0
danceability_%	67.0	67.0	69.0	69.0	96.0	96.0	14.0	14.0
energy_%	64.0	64.0	66.0	66.0	97.0	97.0	17.0	16.0

En la Figura 2 se presenta la distribución de la variable `danceability_%` antes y después del tratamiento de valores atípicos. Inicialmente, se observan algunos valores extremos que amplían el rango de los datos. Tras el tratamiento, estos valores son eliminados, lo que reduce ligeramente la dispersión; sin embargo, la mediana y los cuartiles se mantienen prácticamente iguales. Esto indica que la estructura central de la distribución no se ve afectada, permitiendo reducir la influencia de outliers sin introducir sesgos en los datos (Merino Huerta, 2026).



Codificación de categóricas:

Para la codificación de las variables categóricas **key** y **mode**, se evaluaron dos métodos comunes: El **Label Encoding** que asigna un valor numérico a cada categoría, mientras que **One Hot Encoding** genera variables binarias independientes para cada una.

En este caso, la variable **key** representa la tonalidad musical de la canción y contiene múltiples categorías sin un orden propio, por lo que se utilizó **One Hot Encoding**, evitando así introducir relaciones artificiales entre sus valores. Por otro parte, la variable **mode** indica si la tonalidad es mayor o menor, por lo que al ser binaria se codificó mediante **Label Encoding**, asignando valores numéricos para Minor = 0 y Major = 1. Esta decisión nos permite una representación más simple y liviana sin aumentar innecesariamente la dimensionalidad del dataset.

4. Discusión

Los resultados obtenidos muestran la importancia del preprocesamiento en el análisis de datos. El tratamiento de valores atípicos en **streams** nos permitió reducir el impacto de canciones con niveles de popularidad extremadamente altos, logrando que los datos representen de mejor manera el comportamiento general. En cambio, en **danceability_%** no se observaron cambios importantes, lo que indica que esta variable ya tenía una distribución más estable. Esto se relaciona directamente con los objetivos de la asignatura, ya que permite ver cómo la limpieza y preparación de los datos influyen en la calidad del análisis.

En cuanto a la codificación, se aplicó *One Hot Encoding* en **key** para evitar generar relaciones que no existen entre sus categorías, mientras que **mode** se codificó mediante *Label Encoding* al ser una variable binaria. Estas decisiones permiten trabajar con los datos de forma más clara y adecuada para análisis posteriores.

Como limitaciones, el tratamiento de outliers puede implicar la pérdida de información asociada a casos poco comunes, pero relevantes. Además, posibles inconsistencias en los datos o la falta de un contexto del dataset pueden afectar la interpretación de los resultados. Como mejora, se podrían probar otros métodos de tratamiento de outliers, comparar distintas formas de codificación o trabajar con otros datasets musicales para validar los resultados.

5. Conclusiones

En este análisis se abordaron etapas clave del preprocesamiento de datos, como el tratamiento de valores atípicos, la revisión de distribuciones y la codificación de variables categóricas. Estos procesos permitieron obtener un dataset más consistente y adecuado para su análisis.

En conclusión, los resultados nos muestran que no todas las transformaciones generan cambios visibles, pero aun así son necesarias para asegurar la calidad de los datos. Este tipo de procesos es fundamental en el análisis de datos reales, ya que nos permite trabajar con información más confiable y obtener conclusiones más sólidas.

6. Bibliografía

Han, J., Kamber, M., & Pei, J. (2012). Data mining: Concepts and techniques. Morgan Kaufmann.

Merino Huerta, B. R. (2026). Análisis y Limpieza de datos - Dataset Spotify 2023 en Google Colab. *Notebook no publicado*.

Peña Ancavil, E. (2026). Dataset Spotify 2023 (versión modificada). Material de cátedra no publicado.

Peña Ancavil, E. (2026). Clase03 en Google Colab. *Notebook no publicado*.

Knaflitz, C. N. (2015). Storytelling with data: A data visualization guide for business professionals. Wiley.